

Qwen3-0.6B · prompts 30k + 5k + 10 tokens · max_tokens=256 · ratio 2.42x

